

基于 CCA 和 FBCCA 的无训练场景 SSVEP 频率识别

谢东明

摘要 稳态视觉诱发电位(Steady-State Visual Evoked Potential, SSVEP)是 BCI 系统常见的一种信号, 指人眼受到某个固定频率的视觉刺激时, 大脑皮层相关区域的电位活动会呈现出一个相关的响应. SSVEP 的频率识别是一个重要的问题, 在实验中可以设置不同闪烁频率的目标, 通过频率识别确定受试者的视线在哪个目标上, 精确地识别频率能够帮助研究者更好地进行下游任务. 本文对原始信号进行了合理的滤波, 剔除了高低频噪声, 然后使用典型相关分析(Canonical Correlation Analysis, CCA)和滤波器组典型相关分析(Filter Bank Canonical Correlation Analysis, FBCCA)两种方法进行频率识别, 比较两种方法发现 CCA 运行速度更快, FBCCA 准确率更高, 在 Benchmark 数据集上能够达到 98.65%准确率, 为了追求准确率采用 FBCCA 在无训练场景下对测试集进行预测.

关键词 脑机接口, 稳态视觉诱发电位, 典型相关分析, 滤波器组典型相关分析, 无训练场景

稳态视觉诱发电位(SSVEP)是一种基于脑电图(EEG)信号的神经生理现象, 当人眼受到特定频率的视觉刺激时, 大脑皮层相关区域的电位活动会呈现出与刺激频率相关的响应. 这种响应通常包含与刺激频率相同的成分以及其高次谐波成分. SSVEP 技术被广泛应用于脑机接口(BCI)系统中, 作为一种非侵入性的方式来实现人机交互.

典型的 SSVEP 系统通常在屏幕上排列多个目标, 每个目标以不同的频率和初始相位进行闪烁. 用户通过注视其中一个目标来选择其关注的内容. 在用户注视目标时, 其 EEG 信号会呈现出与所选择目标相关的频率信息. 通过分析用户当前 EEG 信号中的频率信息, 可以确定用户关注的目标, 从而实现与计算机或其他外部设备的交互.

本文的目的是研究有效的算法来检测 SSVEP 信号中的频率信息, 以实现准确和实时的频率识别. 在 SSVEP 信号的波形和频谱图中, 可以观察到明显的频率特征, 包括与目标刺激频率及其倍频处的幅值明显高于其他频率. 基于这些特征, 本文使用典型相关分析(CCA)和滤波器组典型相关分析(FBCCA)两种算法, 对比分析二者在数据集上的表现.

本文的组织架构如下: 第 1 节介绍 CCA 算法原理以及算法在 Benchmark 数据集上的表现; 第 2 节介绍 FBCCA 算法原理以及在 Benchmark 数据集上的表现; 第 3 节使用

FBCCA 在无训练场景下对 SSVEP 数据集进行频率识别, 预测对应的标签; 第 4 节给出本文的结论.

1 CCA 算法

在 SSVEP 系统中, 通常采集多个通道的时序 EEG 信号, 相应的, 我们可以根据实验设定的频率设计模板序列, 用多个通道的时间序列表示基波和谐波. 然而, 多通道的采集信号和多通道的模板序列难以直接计算相关系数, CCA 算法很好地解决了这个问题.

1.1 原理

CCA 算法的核心思想, 是将采集信号和模板序列分别变换到一维, 在一维空间中求皮尔逊相关系数, 因此原问题转化为优化问题: 求变换向量, 使得皮尔逊相关系数最大. 逐一比较各个频率模板的相关系数, 最大相关系数对应的频率即为匹配频率.




图 1 CCA 算法示意图^[1]

m 个通道, n 个采样点的采样信号记为 $X \in R^{m \times n}$, 采样频率记为 f_s , 闪烁频率为 f 且包含 N_h 阶谐波的模板序列 $Y \in R^{2N_h \times n}$ 表示如下:

$$Y = \begin{bmatrix} \sin\left(\frac{2\pi f}{f_s}\right) & \sin\left(\frac{4\pi f}{f_s}\right) & \dots & \sin\left(\frac{2n\pi f}{f_s}\right) \\ \cos\left(\frac{2\pi f}{f_s}\right) & \cos\left(\frac{4\pi f}{f_s}\right) & \dots & \cos\left(\frac{2n\pi f}{f_s}\right) \\ \sin\left(\frac{4\pi f}{f_s}\right) & \sin\left(\frac{8\pi f}{f_s}\right) & \dots & \sin\left(\frac{4n\pi f}{f_s}\right) \\ \cos\left(\frac{4\pi f}{f_s}\right) & \cos\left(\frac{8\pi f}{f_s}\right) & \dots & \cos\left(\frac{4n\pi f}{f_s}\right) \\ \vdots & \vdots & \ddots & \vdots \\ \sin\left(\frac{2\pi N_h f}{f_s}\right) & \sin\left(\frac{4\pi N_h f}{f_s}\right) & \dots & \sin\left(\frac{2n\pi N_h f}{f_s}\right) \\ \cos\left(\frac{2\pi N_h f}{f_s}\right) & \cos\left(\frac{4\pi N_h f}{f_s}\right) & \dots & \cos\left(\frac{2n\pi N_h f}{f_s}\right) \end{bmatrix} \quad (1)$$

对于采集信号 X 和模板序列 Y , 首先分别减去均值使其均值为 0, 然后分别使用权重向量 $W_X \in R^{m \times 1}$ 和 $W_Y \in R^{2N_h \times 1}$ 将二者变换到一维:

$$\begin{aligned} X' &= X^T W_X \\ Y' &= Y^T W_Y \end{aligned} \quad (2)$$

因此, 可以求出 X' 和 Y' 的皮尔逊相关系数:

$$\begin{aligned} \rho_{X', Y'} &= \frac{E[(X')^T Y']}{\sqrt{E[(X')^T X'] E[(Y')^T Y']}} \\ &= \frac{W_X^T X Y^T W_Y}{\sqrt{(W_X^T X X^T W_X) (W_Y^T Y Y^T W_Y)}} \end{aligned} \quad (3)$$

不失一般性, 假设 $W_X^T X X^T W_X = 1$, $W_Y^T Y Y^T W_Y = 1$, 最大化系数 $\rho_{X', Y'}$ 转化为优化问题:

$$\begin{aligned} \max_{W_X, W_Y} & W_X^T X Y^T W_Y \\ \text{s.t. } & W_X^T X X^T W_X = 1 \\ & W_Y^T Y Y^T W_Y = 1 \end{aligned} \quad (4)$$

构造拉格朗日函数如下:

$$L(W_X, W_Y, \lambda_1, \lambda_2) = W_X^T X Y^T W_Y - \frac{\lambda_1}{2} (W_X^T X X^T W_X - 1) - \frac{\lambda_2}{2} (W_Y^T Y Y^T W_Y - 1) \quad (5)$$

令偏导数等于零可得:

$$\begin{cases} \frac{\partial L}{\partial W_X} = X Y^T W_Y - \lambda_1 X X^T W_X = 0 \\ \frac{\partial L}{\partial W_Y} = Y X^T W_X - \lambda_2 Y Y^T W_Y = 0 \end{cases} \quad (6)$$

结合等式约束联立解得:

$$\begin{cases} \lambda_1 = \lambda_2 = \lambda = W_X^T X Y^T W_Y \\ (X X^T)^{-1} X Y^T (Y Y^T)^{-1} Y X^T W_X = \lambda^2 W_X \\ (Y Y^T)^{-1} Y X^T (X X^T)^{-1} X Y^T W_Y = \lambda^2 W_Y \end{cases} \quad (7)$$

其中 λ 的值与皮尔逊相关系数相等, W_X , W_Y 分别是矩阵 $(X X^T)^{-1} X Y^T (Y Y^T)^{-1} Y X^T$, $(Y Y^T)^{-1} Y X^T (X X^T)^{-1} X Y^T$ 的特征向量, 特征值均为 λ^2 . 因此, 只需对矩阵进行特征值分解, 找到最大特征值和对应的特征向量即可求解变换向量和相关系数.

1.2 实验

本文使用清华大学发布的 SSVEP Benchmark 数据集^[2], 采集自 35 位受试者, 数据类型为四维数组, 由 64 个通道, 1500 个采样点, 40 个 trial, 6 个 block 组成, 采样频率为 250Hz. 每个 trial 包含 6s 的数据, 包括 0.5s 的开始偏置和 0.5s 的结束偏置.

本次实验是使用 64 个通道中与稳态视觉诱发电位相关的 9 个通道: Pz, PO5, PO3, POz, PO4, PO6, O1, Oz, O2, 考虑 0.14s 的视觉延迟, 截取每个 trial 中 0.64s~5.5s 的采样点. 首先使用带通滤波器保留 8Hz~90Hz 的信号, 然后对滤波后的信号使用 CCA 算法, 选取谐波次数 $N_h = 5$ 进行频率识别, 运行时间较短, 得到总识别率为 94.36%, 各 trial, block 识别率如下所示:




图2 CCA 算法识别率

2 FBCCA 算法

原 CCA 算法存在一些缺陷, CCA 在处理 SSVEP 信号时忽略了频率信息, 将所有频率的信号整合在一起进行分析, 无法准确区分和提取多个频率成分和高次谐波成分之间的关联信息. FBCCA 算法使用一个滤波器组对原信号进行滤波, 得到不同频率区间的特征, 然后将滤波后的信号逐一与模板进行比对, 最后将结果进行组合, 充分利用各种频率成分.

2.1 原理

FBCCA 算法使用一组 N 个带通滤波器对原信号进行滤波, 得到处理信号 X_1, X_2, \dots, X_N , 然后与频率 $f_k, k=1, 2, \dots, K$ 的模板序列 Y_k 使用 CCA 算法计算相关系数得到 $\rho_k^1, \rho_k^2, \dots, \rho_k^N$, 将 N 个系数按照如下方式组合^[3]:

$$\tilde{\rho}_k = \sum_{n=1}^N w(n) \cdot (\rho_k^n)^2 \quad (8)$$

$$w(n) = n^{-a} + b$$

其中 a, b 为可调参数. 将 $\tilde{\rho}_k$ 作为比较的标准, 在 K 个系数中最大的 $\tilde{\rho}_k$ 对应频率即为预测频率:

$$\tilde{f} = f_{\arg \max_k \tilde{\rho}_k} \quad (9)$$

2.2 滤波器组设计

三种滤波器组结构如下所示:




图3 FBCCA 滤波器组^[3]

2.3 实验

仍然使用 SSVEP Benchmark 数据集进行测试, 调参后得到谐波次数选取 $N_h = 4$, 滤波器组选型号 3(M3), 滤波器数量 $N = 7$, 系数 $a = 1, b = 0.5$ 时准确率最高, 运行时间较长, 总准确率达到 98.65%, 各 trial, block 识别率如下所示:




图4 FBCCA 算法识别率

3 无训练场景 SSVEP 识别

本节使用上述讨论的算法, 对给定的 SSVEP 数据集进行无训练频率识别. 数据包括 5 名受试者, 每名受试者有 2 个 block, 22 个 trial, 10 个通道, 采样频率为 1000Hz, 采样时长 4s.

首先对采样信号降采样到 250Hz, 然后考虑视觉延迟, 截取 0.16s 后的数据, 最后使用 8~50Hz 带通滤波器去除高低频噪声, 完成数据预处理.

根据之前的讨论, FBCCA 算法具有更高的准确率, 因此预测使用 FBCCA 算法, 实验中使用的参数为: $N_h = 4$, M3, $N = 7$, $a = 1.25$, $b = 0.25$, 带通滤波器组频带为 $8 + 4(n-1) \sim 50\text{Hz}, n=1, 2, \dots, N$ 预测结果如下所示:




图5 无训练场景预测结果

4 结论

本文讨论了 CCA 和 FBCCA 两种算法在 Benchmark 数据集上的表现,二者准确率都很高但后者更高,接近 100%;在速度方面,CCA 算法运行速度比 FBCCA 算法快几倍.在实际应用中,速度和准确率都是重要的标准,需要在二者之间权衡:更追求速度时可以使用 CCA 算法,更追求准确率时可以使用 FBCCA 算法.本文还对无训练场景下 SSVEP 数据集进行了预测,由于数据集规模较小,两种算法运行时间都不长,因此选用 FBCCA 算法追求更高的准确率.

References

1. Lin, C. Zhang, W. Wu, X. Gao. Frequency recognition based on canonical correlation analysis for SSVEP-based BCIs. IEEE Trans. on Biomedical Engineering, 2006, 53(12):2610–2614.
2. Wang Y J, Chen X G, Gao X R, et al. A benchmark dataset for SSVEP-based brain-computer interfaces. Vision Research, 2017, 25: 1746–1752
3. X. Chen, Y. Wang, S. Gao, T.-P. Jung, X. Gao. Filter bank canonical correlation analysis for implementing a high-speed SSVEP-based brain-computer interface. Journal of Neural Engineering, 2015, 12(4):046008.